

Análise Exploratória de Dados com Pandas.

Extraindo os principais insights ...



EDA

com Pandas

O objetivo da **Análise Exploratória de Dados (EDA – Exploratory Data Analysis)** é dar uma boa espiada nos dados antes de começar a fazer coisas mais complicadas. É como o investigador curioso que olha primeiro para entender do que se trata. A análise ajuda a descobrir **segredos escondidos** nos números, **padrões estranhos** e até **erros**, para que possamos tomar decisões mais inteligentes e contar histórias mais interessantes com nossos dados. É como a primeira pista em um quebra-cabeça gigante de informações.

EDA

Com Pandas

01. **O que é EDA?**
 02. **O que é a biblioteca Pandas?**
 03. **Coleta e Preparação de Dados**
 04. **Lidando com dados ausentes**
 05. **Formulando hipóteses**
 06. **Análise Univariada**
 07. **Análise Bivariada**
 08. **Lidando com Outliers**
 09. **Automatizando EDA**
-

O que é EDA ?

Coleta e
Preparação de
Dados

Formulação de
Hipóteses

Análise Univariada

Análise Bivariada

Análise Multivariada

Análise Temporal

Comunicação
dos Resultados

Lidar com valores ausentes e outliers

EDA é um processo sistemático usado em projetos de ciência de dados para entender e resumir as características fundamentais de um conjunto de dados.

O que é a biblioteca Pandas

O **Pandas** é uma biblioteca de **Python** amplamente usada para análise de dados. Sua principal vantagem é sua capacidade de **manipular**, **limpar** e **analisar** dados de forma eficiente. Ele fornece estruturas de dados flexíveis, como **Series** e **DataFrames**, que permitem organizar dados em tabelas, realizar operações complexas, como **filtros** e **agregações**, e facilitar a **visualização** dos resultados. O **Pandas** também é compatível com **várias fontes de dados**, como arquivos **CSV**, **Excel** e **bancos de dados**, tornando-o essencial para cientistas de dados e analistas que desejam explorar e extrair insights de dados de maneira eficaz e intuitiva.

O contexto do nosso problema


O contexto que iremos analisar neste módulo de Análise Exploratória é do **segmento de telecom**. A empresa possui três conjuntos de dados de clientes e serviços, com uma variável que determina se o cliente **abandonou (churn)** ou não a empresa de telecom.

O intuito é que com estes conjuntos de dados e com base em algumas hipóteses que iremos formular e que serão respondidas pelo EDA, possa obter alguns **insights iniciais** para a construção de inteligência artificial que possa “**prever**” o abandono de clientes **ainda ativos**.

Coleta e Preparação de Dados

01. **Leitura de arquivos**
 02. **Transformação de tipos de dados**
 03. **Renomear colunas**
 04. **Unificação de conjuntos de dados**
-

Let's Go, Let's Go



Code time ...

Lidar com dados ausentes

01. **Tipos de dados ausentes**
 02. **Detecção de dados ausentes**
 03. **Remoção de dados ausentes**
 04. **Imputação de dados ausentes**
-

Tipos de dados ausentes

Dados faltantes completamente ao acaso (MCAR - Missing Completely at Random)

O fato de que um certo valor está faltando não tem nada a ver com seu valor hipotético e com os valores de outras variáveis.


Dados faltantes ao acaso (MAR - Missing at Random)

Faltar dados aleatoriamente significa que a propensão para um ponto de dados estar ausente não está relacionada aos dados ausentes, mas está relacionada a alguns dos dados observados.

Dados faltantes não ao acaso (MNAR - Missing not at Random)

Duas razões possíveis são que o valor ausente depende do valor hipotético ou o valor ausente depende do valor de alguma outra variável.

Let's Go, Let's Go



Code time ...

Formulando hipóteses

Use a Intuição

Comece com suas suspeitas iniciais com base no conhecimento do domínio. Pergunte a si mesmo o que você espera encontrar nos dados.

Seja Específico

Suas hipóteses devem ser claras e específicas. Evite afirmações vagas, como "os dados têm alguma tendência". Em vez disso, seja concreto, como "o aumento nas vendas está relacionado ao lançamento de um novo produto".

Testabilidade

Certifique-se de que suas hipóteses possam ser testadas com os dados disponíveis. Você deve ser capaz de encontrar evidências nos dados que confirmem ou refutem a hipótese.

Considere Relações

Pense em como diferentes variáveis podem estar relacionadas. Por exemplo, "a idade dos clientes afeta a taxa de churn?" ou "a localização geográfica influencia as preferências de compra?".

Formulando hipóteses

Utilize Visualizações

A EDA frequentemente envolve gráficos e visualizações. Use-os para explorar seus dados e validar suas hipóteses. Por exemplo, crie gráficos de dispersão para verificar relações entre variáveis.

Seja Aberto a Surpresas

Esteja preparado para encontrar resultados inesperados. Às vezes, as melhores descobertas ocorrem quando as hipóteses iniciais são desafiadas.

Evite Hipóteses de Causa e Efeito Prematuras

Evite assumir causalidade imediatamente. Por exemplo, "A promoção de um produto causou um aumento nas vendas". Primeiro, explore a correlação e, em seguida, avalie a causalidade.

Refine e Atualize

À medida que você realiza a EDA e coleta mais informações, refine e atualize suas hipóteses conforme necessário. Este é um processo iterativo.

Formulação de Hipóteses

01. **A faixa etária do cliente tem uma forte associação com o churn**
02. **Um cliente que com menos de 6 meses de contrato ativo é mais propenso ao Churn**
03. **Cliente com contratos mensais são mais propensos ao Churn**


Análise Univariada

A análise univariada é uma **abordagem estatística** que se concentra na análise de **uma única variável** em um conjunto de dados. Ela visa compreender as características individuais dessa variável, examinando sua **distribuição, medidas resumo** (como média e mediana), **variabilidade** e a **presença de valores atípicos (outliers)**. Isso ajuda a obter uma visão detalhada das características de uma variável específica, antes de explorar relações com outras variáveis (análise bivariada ou multivariada) durante a análise de dados.

Análise Univariada

- 01. **Distribuição**
 - 02. **Medidas de Posição**
 - 03. **Medidas de Dispersão**
-

Let's Go, Let's Go



Code time ...


Análise Bivariada

A análise bivariada é uma **técnica estatística** que se concentra na **relação entre duas variáveis** em um conjunto de dados. Ela busca entender como uma variável está relacionada à outra, frequentemente usando **gráficos, tabelas cruzadas e cálculos de correlação**. Isso ajuda a identificar **padrões, associações e dependências** entre as duas variáveis, fornecendo **insights** sobre como elas interagem, o que é crucial na análise de dados e na tomada de decisões informadas.

Análise Bivariada

- 01. Análise de Correlação
- 02. Tabelas Cruzadas

Let's Go, Let's Go



Code time ...

Outliers (Valores atípicos)

Um **outlier** é um dado que é muito diferente dos outros dados em um conjunto de dados. É como um **ponto fora da curva**.

Por exemplo, imagine que você tem um conjunto de dados que registra a altura de 100 pessoas. A média das alturas é de 1,70 metros. Um outlier seria uma pessoa que tem 2,50 metros de altura. Essa pessoa é muito mais alta do que as outras, então ela é considerada um outlier.

Outliers podem ser causados por vários fatores, como **erros de medição, dados incompletos ou eventos aleatórios**. Eles podem afetar os resultados de uma análise de dados, então é importante identificá-los e lidar com eles de forma adequada.

Lidando com Outliers

Identificação e Documentação

Identifique os outliers em seus dados e documente-os. Compreender a natureza dos outliers é fundamental.

Remoção

Em alguns casos, você pode optar por remover os outliers do conjunto de dados, desde que isso seja justificável e não distorça a análise.

Transformação de Dados

Aplicar transformações matemáticas aos dados, como logaritmo ou raiz quadrada, pode reduzir o impacto dos outliers.

Binning (Agrupamento)

Dividir os dados em intervalos (bins) pode ajudar a reduzir a influência de outliers ao transformar a variável em categórica.

Lidando com Outliers

Substituição

Substituir outliers por valores mais representativos, como a mediana, a média truncada ou valores interpolados.

Modelagem Robusta

Usar algoritmos de modelagem mais robustos a outliers, como regressão robusta ou métodos de aprendizado de máquina robustos.

Análise Separada

Realizar análises separadas para dados com e sem outliers para avaliar o impacto deles nas conclusões.

Entender a Causa


Se possível, investigar a causa dos outliers para determinar se são erros de medição ou representam informações legítimas.

Lidando com Outliers

01.

Detecção de Outliers

Let's Go, Let's Go



Code time ...

Automatizando EDA

A automatização da análise exploratória de dados (EDA) oferece uma série de vantagens, incluindo:

Aumento da velocidade e da eficiência: A EDA automatizada pode ser executada muito mais rapidamente do que a EDA manual. Isso pode ser importante para conjuntos de dados grandes ou complexos.

Redução da subjetividade: A EDA automatizada é menos propensa a erros ou vieses humanos. Isso pode levar a análises mais precisas e confiáveis.


Melhor compreensão dos dados: A EDA automatizada pode identificar padrões e tendências que podem não ser óbvios para os analistas humanos. Isso pode ajudar a obter uma melhor compreensão dos dados e a tomar melhores decisões.

Automatizando EDA

01.

Sweetviz

Let's Go, Let's Go



Code time ...



Boosting People.

rocketseat.com.br
